

VM_FOOTBALL

Sistema de Visión por Computadora para Análisis de Fútbol

Documentación Técnica del Repositorio

Alejandro Rafael Vega Saavedra
Juan Sebastián Rodríguez Salazar

Universidad del Rosario
Escuela de Ciencia e Ingeniería
Programa de Visión por Computadora

Resumen

El análisis de rendimiento y evaluación táctica en el fútbol colombiano y latinoamericano depende en gran medida de métodos manuales que limitan la profundidad y cantidad de información extraíble. Además, las herramientas comerciales de análisis automático no están diseñadas para las condiciones de transmisión televisiva local, presentando fallos en iluminación, ángulos de cámara y calidad de video propios de las producciones regionales. Este trabajo aborda esta brecha mediante el desarrollo de VM_FOOTBALL, un sistema integral de visión por computadora basado en modelos de inteligencia artificial para la detección, segmentación, seguimiento y análisis de jugadores, balón y árbitros en partidos de fútbol.

La metodología adoptada es de enfoque cuantitativo, experimental y aplicado, estructurada en cinco fases principales: adquisición y preprocesamiento de datos, entrenamiento y *fine-tuning* de modelos, segmentación y seguimiento, clasificación de equipos y reconocimiento de dorsales, y evaluación cuantitativa del desempeño. El sistema integra modelos de última generación como RF-DETR para detección basada en transformadores, SAM2 para segmentación con memoria temporal, arquitecturas YOLO (YOLOv8n y YOLOv11n) como referencia comparativa, SmoIVLM2 y ResNet para reconocimiento de dorsales, y clasificación automática de equipos mediante *clustering* K-means sobre *embeddings* de SigLIP2 reforzado con descriptores HSV. Los datos provienen del *dataset* SoccerNet-MOT, complementados con material de YouTube, permitiendo adaptar los modelos al contexto visual colombiano mediante *fine-tuning*.

Los resultados demuestran que el sistema es capaz de detectar y seguir múltiples objetos en tiempo real, mantener identidades a lo largo de secuencias con oclusiones y cambios de iluminación, y clasificar jugadores por equipo sin requerir etiquetas manuales. La evaluación se realizó mediante métricas estándar como mAP@0.5, precisión, *recall*, F1-score, IoU, *Character Accuracy Rate*, *Top-k Accuracy* y *Silhouette Coefficient*. Este trabajo establece las bases técnicas y metodológicas para una plataforma de análisis táctico asistida por IA, democratizando el acceso a herramientas avanzadas en el contexto del fútbol profesional y formativo latinoamericano.

Palabras clave: Visión por computadora, detección de objetos, seguimiento múltiple, aprendizaje profundo, YOLO, RF-DETR, SAM2, análisis deportivo, fútbol, *clustering*, reconocimiento óptico de caracteres, modelos multimodales, SoccerNet, *fine-tuning*.

Abstract

Performance analysis and tactical evaluation in Colombian and Latin American soccer rely heavily on manual methods that limit the depth and quantity of extractable information. Moreover, commercial automatic analysis tools are not designed for local television broadcast conditions, exhibiting failures in lighting, camera angles, and video quality characteristic of regional productions. This work addresses this gap through the development of VM_FOOTBALL, a comprehensive computer vision system based on artificial intelligence models for detection, segmentation, tracking, and analysis of players, ball, and referees in soccer matches.

The adopted methodology follows a quantitative, experimental, and applied approach, structured in five main phases: data acquisition and preprocessing, model training and fine-tuning, segmentation and tracking, team classification and jersey number recognition, and quantitative performance evaluation. The system integrates state-of-the-art models such as RF-DETR for transformer-based detection, SAM2 for segmentation with temporal memory, YOLO architectures (YOLOv8n and YOLOv11n) as comparative references, SmolVLM2 and ResNet for jersey number recognition, and automatic team classification through K-means clustering on SigLIP2 embeddings reinforced with HSV descriptors. The data comes from the SoccerNet-MOT dataset, complemented with YouTube material, enabling adaptation of models to the Colombian visual context through fine-tuning.

Results demonstrate that the system is capable of detecting and tracking multiple objects in real-time, maintaining identities throughout sequences with occlusions and lighting changes, and classifying players by team without requiring manual labels. Evaluation was performed using standard metrics such as mAP@0.5, precision, recall, F1-score, IoU, Character Accuracy Rate, Top-k Accuracy, and Silhouette Coefficient. This work establishes the technical and methodological foundations for an AI-assisted tactical analysis platform, democratizing access to advanced tools in the context of professional and youth Latin American soccer.

Keywords: Computer vision, object detection, multi-object tracking, deep learning, YOLO, RF-DETR, SAM2, sports analytics, soccer, clustering, optical character recognition, multi-modal models, SoccerNet, fine-tuning.

Índice general

Resumen	III
Abstract	v
1. INTRODUCCIÓN	1
Introducción	1
2. OBJETIVOS	5
Objetivos	5
2.1. Objetivo general	5
2.2. Objetivos específicos	5
3. PROBLEMA Y JUSTIFICACIÓN	7
Problema y justificación	7
3.1. 3.1. Planteamiento del problema	7
3.2. 3.2. Contexto del problema y relevancia de la solución	8
3.3. 3.3. Importancia, impacto y aplicabilidad del trabajo	9
3.3.1. Impacto técnico	9
3.3.2. Impacto económico	9
3.3.3. Impacto social	9
3.3.4. Impacto académico	9
3.3.5. Relevancia cultural	10
4. MARCO TEÓRICO Y ESTADO DEL ARTE	11
4.1. Conceptos fundamentales	11
4.1.1. Visión por computador	11
4.1.2. Aprendizaje profundo en visión: de las CNN a los transformadores	11
4.1.3. Detección de objetos y detección de objetos pequeños	12
4.1.4. Segmentación y seguimiento (Multi-Object Tracking)	12
4.1.5. . Modelos de visión–lenguaje	12
4.1.6. <i>Clustering</i> y espacios de representación	13

4.2.	Visión por computador en el fútbol profesional: de los estadios de élite a la señal de TV	13
4.3.	Datasets para visión por computadora en fútbol	14
4.3.1.	SoccerNet-Tracking: el benchmark estándar	14
4.3.2.	Datasets alternativos y comparación	15
4.3.3.	Limitaciones de los datasets existentes para el contexto latinoamericano	16
4.4.	Modelos de última generación elegidos para VM_FOOTBALL	17
4.4.1.	RF-DETR: detección basada en transformadores en tiempo real . . .	17
4.4.2.	SAM2: segmentación fundacional con memoria para video	18
4.4.3.	SmolVLM2 como motor de OCR flexible	18
4.4.4.	ResNet como clasificador de dígitos de camiseta	19
4.4.5.	SigLIP2 como generador de <i>embeddings</i> para equipos	19
4.4.6.	Modelos especializados para el balón y detección de objetos pequeños	20
4.5.	Modelos y metodologías en ligas de élite vs. contexto latinoamericano . .	21
4.6.	Conclusión del estado del arte y marco teórico	21
5.	METODOLOGÍA	23
5.1.	Enfoque general	23
5.2.	Selección de modelos y arquitectura del sistema	23
5.3.	Flujo del sistema	24
5.4.	Datos y contexto de entrenamiento	24
5.4.1.	Selección del dataset base y estrategia de adaptación	24
5.4.2.	Organización y procesamiento de los datos	25
5.5.	Entrenamiento y ajuste de los modelos de detección	26
5.6.	Segmentación y seguimiento con SAM2	26
5.7.	Reconocimiento de dorsales y clasificación por equipos	27
5.8.	Evaluación e iteración del <i>pipeline</i>	27
6.	RESULTADOS Y DISCUSIÓN	29
6.1.	Modelos de Detección y Algoritmos	29
6.1.1.	Arquitecturas YOLO Implementadas	29
6.1.2.	Configuraciones de Entrenamiento	29
6.2.	Análisis de Equipos	30
6.2.1.	Algoritmo de Clustering	30
6.2.2.	Implementación del Algoritmo	31
6.2.3.	Persistencia de Resultados	31
7.	CONCLUSIONES	33
	Conclusiones	33
7.1.	Contribuciones	33
7.2.	Conclusiones Generales	33

7.3. Trabajo Futuro	33
Referencias	35
A. Configuraciones y Parámetros	39
A.1. Parámetros de Entrenamiento	39
A.1.1. YOLOv8n - Configuración Base	39
A.1.2. YOLOv11n - Configuración Optimizada	39
A.2. Configuraciones de Clustering	40
A.2.1. Parámetros del Algoritmo K-means	40
A.3. Configuraciones de Visualización	40
A.3.1. Parámetros del Sistema de Renderizado	40
A.4. Estructura de Archivos de Configuración	41
A.4.1. Archivo data.yaml	41
A.4.2. Archivo ball_only.yaml	41
A.5. Variables de Entorno	42
A.5.1. Configuración del Entorno de Desarrollo	42
A.6. Archivos de Metadatos	42
A.6.1. Formato gameinfo.ini	42
A.6.2. Formato seqinfo.ini	42

Capítulo 1

INTRODUCCIÓN

El análisis deportivo ha experimentado una transformación significativa en las últimas décadas, evolucionando desde métodos puramente observacionales hacia sistemas tecnológicos sofisticados que permiten extraer información cuantitativa precisa del juego. En el fútbol profesional europeo y en algunas ligas de élite mundial, esta revolución tecnológica se ha materializado en sistemas de captura multi-cámara, sensores portátiles y plataformas de análisis táctico que generan métricas avanzadas en tiempo real. Sin embargo, esta realidad contrasta marcadamente con la situación en Colombia y Latinoamérica, donde la mayoría de clubes profesionales, equipos formativos y escuelas deportivas continúan dependiendo de métodos manuales para el análisis de partidos y el seguimiento del rendimiento de los jugadores.

VM_FOOTBALL surge como respuesta directa a esta brecha tecnológica. Se trata de un sistema integral de visión por computadora diseñado específicamente para democratizar el acceso al análisis automatizado de partidos de fútbol, con especial énfasis en las condiciones visuales y técnicas propias de las transmisiones televisivas latinoamericanas. A diferencia de las soluciones comerciales existentes, que fueron desarrolladas y optimizadas para contextos europeos con producciones audiovisuales de alta calidad, VM_FOOTBALL está concebido desde el inicio para funcionar eficazmente con las características particulares de las grabaciones locales: variaciones en iluminación, ángulos de cámara no estandarizados, compresión de video significativa y condiciones de transmisión que difieren sustancialmente de los estándares internacionales.

El sistema utiliza técnicas avanzadas de aprendizaje profundo y combina múltiples arquitecturas de última generación para resolver el problema de forma integral. En el núcleo de detección, se implementan y comparan arquitecturas YOLO (You Only Look Once) en sus versiones 8 y 11, junto con RF-DETR, un modelo basado en transformadores que representa el estado del arte en detección de objetos en tiempo real. Para la segmentación y el seguimiento temporal, se integra SAM2 (Segment Anything Model 2), un modelo fundacional desarrollado por Meta que incorpora memoria temporal para mantener la coherencia de las máscaras de segmentación a lo largo de secuencias de video. El reconocimiento de dorsales se aborda mediante una combinación de modelos multimodales visión-lenguaje (SmolVLM2) y

redes neuronales convolucionales especializadas (ResNet), mientras que la clasificación automática de equipos se realiza a través de un algoritmo de *clustering* K-means que opera sobre representaciones vectoriales generadas por SigLIP2, reforzado con descriptores de color en espacio HSV.

El sistema está diseñado para identificar y clasificar múltiples elementos en el campo de juego de manera simultánea: jugadores de ambos equipos, porteros, árbitros y el balón. Esta capacidad de detección multi-objeto se complementa con algoritmos de seguimiento que mantienen la identidad de cada actor a lo largo del tiempo, permitiendo construir trayectorias completas y generar visualizaciones que facilitan el análisis táctico posterior. La arquitectura modular del sistema permite además su extensión futura con nuevas capacidades analíticas, como mapas de calor, análisis de zonas de ocupación, métricas de distancia recorrida o patrones de movimiento colectivo.

Un aspecto fundamental del proyecto es su estrategia de adaptación al contexto colombiano. Aunque los modelos se entrenan inicialmente con el *dataset* SoccerNet-MOT, que proporciona miles de secuencias anotadas de partidos profesionales europeos, el sistema incorpora un proceso sistemático de *fine-tuning* utilizando material audiovisual obtenido de YouTube, así como grabaciones de partidos formativos y semiprofesionales colombianos. Este proceso de especialización permite que los modelos aprendan a manejar las particularidades visuales del fútbol local: uniformes con mayor presencia publicitaria, condiciones de iluminación más variables, resoluciones de video inferiores y características de compresión diferentes a las de los *datasets* de referencia internacionales.

Alcance del Proyecto

El alcance de VM_FOOTBALL se estructura en torno a cinco capacidades principales que, en conjunto, constituyen un sistema completo de análisis visual:

- **Detección automática multi-clase:** El sistema identifica y localiza simultáneamente jugadores, porteros, árbitros y balón en cada fotograma del video, generando cajas delimitadoras con sus coordenadas y niveles de confianza asociados. Esta detección se realiza mediante modelos entrenados específicamente para el dominio del fútbol, capaces de distinguir entre las diferentes categorías de objetos incluso en situaciones de oclusión parcial o aglomeración de jugadores.
- **Segmentación y seguimiento temporal:** Más allá de la simple detección, el sistema produce máscaras de segmentación precisas para cada instancia detectada y mantiene su identidad a lo largo de la secuencia de video. El módulo de seguimiento construye trayectorias estables incluso cuando los jugadores desaparecen momentáneamente del encuadre o cuando la calidad de detección se degrada puntualmente, aprovechando la memoria temporal de SAM2 para mantener la coherencia visual.

- **Clasificación automática por equipos:** Mediante técnicas de *clustering* no supervisado sobre representaciones visuales aprendidas, el sistema agrupa automáticamente a los jugadores según su equipo, sin requerir etiquetas manuales ni configuración previa. El algoritmo es robusto a variaciones en uniformes, condiciones de iluminación y presencia de elementos publicitarios en las camisetas, elementos particularmente relevantes en el contexto latinoamericano.
- **Reconocimiento de dorsales:** El sistema extrae e identifica los números de las camisetas de los jugadores, combinando capacidades de reconocimiento óptico de caracteres con modelos multimodales que entienden el contexto visual. Esta funcionalidad permite asociar cada trayectoria con un jugador específico, facilitando el análisis individual del rendimiento y la generación de estadísticas personalizadas.
- **Visualización y análisis de resultados:** Los resultados del procesamiento se presentan tanto en formato de video anotado, donde se superponen las detecciones, segmentaciones y etiquetas sobre las imágenes originales, como en formatos estructurados (JSON, CSV) que permiten análisis cuantitativos posteriores. El sistema genera además representaciones tácticas del campo que proyectan las posiciones de los jugadores sobre una vista cenital estandarizada.
- **Evaluación comparativa de arquitecturas:** Como parte del desarrollo, el proyecto incluye una evaluación exhaustiva de diferentes arquitecturas de detección (YOLOv8n, YOLOv11n, RF-DETR) bajo las mismas condiciones experimentales, proporcionando evidencia empírica sobre sus fortalezas y debilidades relativas en el contexto específico del fútbol televisado colombiano.

El proyecto se desarrolla con una perspectiva tanto técnica como aplicada. Desde el punto de vista técnico, constituye una exploración sistemática de cómo integrar modelos fundacionales modernos de visión por computadora en un *pipeline* completo para un dominio específico, documentando las decisiones de diseño, los procesos de adaptación y las métricas de evaluación relevantes. Desde la perspectiva aplicada, VM_FOOTBALL busca establecer las bases para una futura plataforma interactiva de análisis táctico que pueda ser utilizada por entrenadores, analistas deportivos, cuerpos técnicos y académicos interesados en el estudio cuantitativo del fútbol, con particular énfasis en hacer estas herramientas accesibles al contexto colombiano y latinoamericano, donde las barreras de costo y complejidad técnica han limitado históricamente su adopción.

Capítulo 2

OBJETIVOS

2.1. Objetivo general

Desarrollar un sistema integral de visión por computador basado en modelos de inteligencia artificial para la detección, segmentación, seguimiento y análisis de jugadores, balón y árbitros en partidos de fútbol, orientado a la generación de información cuantitativa y visual relevante para el estudio del rendimiento y las tácticas de juego, constituyendo la base para una futura plataforma de análisis futbolístico asistida por inteligencia artificial adaptada al contexto colombiano y latinoamericano.

2.2. Objetivos específicos

1. Integrar y preprocesar datos multifuente provenientes del *dataset SoccerNet-MOT*, de los resúmenes oficiales del canal **Win Sports** (*YouTube*), y de grabaciones de fútbol formativo y semiprofesional colombiano, garantizando su estandarización, limpieza y segmentación en conjuntos adecuados para el entrenamiento, validación y prueba de los modelos.
2. Entrenar y comparar múltiples arquitecturas de detección y análisis (**YOLOv8n**, **YOLOv11n**, **RF-DETR**, **SAM2**), evaluando su desempeño mediante métricas estándar como **mAP@0.5**, **precisión**, **recall**, **F1-score** e **IoU promedio**, con énfasis en la detección de objetos pequeños como el balón.
3. Implementar un proceso de ajuste fino (*fine-tuning*) utilizando material audiovisual del contexto colombiano y latinoamericano, con el propósito de adaptar los modelos preentrenados y mejorar su capacidad de generalización frente a variaciones en iluminación, uniformes, compresión de video y ángulos de cámara característicos de las transmisiones televisivas locales.
4. Desarrollar módulos complementarios de segmentación, reconocimiento óptico de caracteres (OCR) y clasificación automática, integrando modelos como **SAM2** para

segmentación con memoria temporal, **SmolVLM2** y **ResNet** para el reconocimiento automático de dorsales, y **SigLIP2** combinado con el algoritmo **K-means** para el agrupamiento no supervisado de jugadores por equipo.

5. Evaluar el sistema propuesto de forma integral mediante métricas específicas para cada módulo: **mAP@0.5**, **precisión**, **recall** y **F1-score** para detección y seguimiento; **Character Accuracy Rate (CAR)** y **Top-k Accuracy** para OCR de dorsales; y **Silhouette Coefficient** para *clustering*, comparando el rendimiento entre los modelos base preentrenados y las versiones adaptadas con material audiovisual colombiano.
6. Establecer las bases técnicas y metodológicas para el desarrollo de una plataforma interactiva de análisis táctico, incluyendo un *pipeline* completo de procesamiento, formatos de salida estructurados, procesos documentados de adaptación de modelos y visualizaciones interpretables, orientadas a entrenadores, analistas deportivos, cuerpos técnicos del fútbol profesional y formativo, e investigadores del área.

Capítulo 3

PROBLEMA Y JUSTIFICACIÓN

3.1. 3.1. Planteamiento del problema

El fútbol es un deporte que, en Colombia y en gran parte de Latinoamérica, tiene una importancia social, se vive con pasión, trasciende un sinnúmero de barreras y crea comunidades en torno a una identidad, la cual es la representada por una entidad deportiva. Tiene un impacto cultural y económico que trasciende lo puramente deportivo. Sin embargo, a pesar de su relevancia, hoy en día los procesos de análisis de rendimiento y evaluación táctica siguen siendo, en la mayoría de los casos, métodos manuales que dependen de la observación subjetiva y del tiempo disponible por parte de analistas, entrenadores o miembros del cuerpo técnico.

La realidad en el contexto latinoamericano, y más en el colombiano, es que gran parte del análisis que se realiza en torneos profesionales y formativos consiste en revisar grabaciones de partidos, retroceder secuencias, detener el video en momentos puntuales y anotar observaciones de manera independiente. Este procedimiento no solo es lento, sino que también limita la profundidad y cantidad de información que se puede obtener, especialmente cuando se busca identificar patrones que requieren consistencia y precisión.

A este problema se suma una dificultad técnica que ha sido muy poco estudiada en el contexto colombiano: la mayoría de herramientas avanzadas de análisis automático no están diseñadas para el tipo de transmisión televisiva que se utiliza en el país. Las condiciones de iluminación, los ángulos de cámara, la calidad del video, los colores de los uniformes y las variaciones de señal afectan el desempeño de modelos de visión por computador entrenados con *datasets* de Europa, Estados Unidos o ligas con producciones audiovisuales de alta calidad. Como consecuencia, incluso los modelos más sofisticados presentan fallos cuando se aplican a partidos transmitidos en Colombia. Esta falta de adaptación limita la posibilidad de adoptar tecnologías modernas en clubes con recursos limitados y herramientas de *software* costosas o no adecuadas al entorno local.

El problema central que motivó este trabajo surge de esa brecha: existe una necesidad real de automatizar o mejorar el análisis futbolístico y la extracción de los mismos datos, pero las soluciones actuales no funcionan adecuadamente con la realidad audiovisual del fútbol colombiano. Además, las instituciones deportivas que podrían beneficiarse de estas herra-

mientas se encuentran con barreras de costo, complejidad técnica, desconocimiento técnico para implementarlas *in-house* o falta de acceso a modelos eficientes, abiertos y adaptables. Esto impide avanzar hacia un análisis más objetivo, profundo y basado en datos, lo cual afecta directamente la toma de decisiones tácticas, el seguimiento de jugadores, la formación de talento joven y la capacidad de competir en escenarios profesionales cada vez más demandantes.

En síntesis, el problema se puede describir como la falta de un sistema integral que permita detectar, seguir, identificar y analizar a los jugadores y el balón en partidos de fútbol grabados en condiciones reales del contexto colombiano, utilizando modelos de inteligencia artificial de última generación que puedan ser reentrenados y ajustados a partir de material audiovisual local.

3.2. Contexto del problema y relevancia de la solución

La solución planteada en esta tesis aparece en un momento donde la inteligencia artificial ha demostrado avances extraordinarios en visión por computador, particularmente en tareas como detección, segmentación, seguimiento y reconocimiento de objetos. Sin embargo, la mayoría de avances recientes se han desarrollado y validado en contextos que no representan las condiciones del fútbol latinoamericano. Como resultado, existe una oportunidad concreta de aplicar estos avances en un entorno real que históricamente no ha sido atendido por la comunidad académica ni por la industria del análisis deportivo.

En Colombia y Latinoamérica, el análisis táctico y técnico se concentra principalmente en equipos profesionales de alto rendimiento o selecciones nacionales, y aun así, las herramientas especializadas suelen ser costosas y cerradas. Las escuelas de formación, los clubes regionales e incluso muchos equipos de primera división trabajan todavía con metodologías tradicionales, lo que deja un espacio muy limitado para desarrollar análisis avanzados o métricas modernas como zonas de ocupación, densidades defensivas, trayectorias de alta precisión o patrones colectivos. La disponibilidad de un sistema de visión por computador adaptado a estos entornos permitiría democratizar el acceso al análisis moderno del fútbol, abriendo nuevas posibilidades para el desarrollo deportivo.

La relevancia académica radica en que este trabajo integra modelos de última generación como RF-DETR, SAM2, YOLO, SigLIP y SmolVLM2, combinándolos con modelos tradicionales como K-means y agrupándolos así mismo en un *pipeline* completo y ajustado a un dominio específico. Pocos estudios han explorado cómo estas arquitecturas interactúan entre sí en un entorno deportivo real, y aún menos en condiciones audiovisuales latinoamericanas. Este proyecto también aporta un enfoque metodológico replicable, donde se demuestra cómo utilizar material de transmisión televisiva local o grabaciones de partidos semiprofesionales o formativos para reentrenar modelos y mejorar su capacidad de generalización. Esto representa un avance para la investigación en visión por computador aplicada a deportes en contextos emergentes.

La relevancia técnica es clara: un sistema que detecta jugadores, identifica dorsales, sigue trayectorias, agrupa equipos por uniformes y mapea el campo a coordenadas tácticas puede

transformar la manera en que se entienden los partidos. Además, la integración de modelos abiertos y reentrenables garantiza que el sistema pueda seguir mejorando con más datos y con nuevas herramientas que surjan en el futuro.

3.3. 3.3. Importancia, impacto y aplicabilidad del trabajo

El impacto de este proyecto puede analizarse desde diferentes perspectivas.

3.3.1. Impacto técnico

El sistema propuesto automatiza una serie de tareas que normalmente demandan horas de trabajo humano. La detección y seguimiento de jugadores y balón, el reconocimiento de dorsales, el agrupamiento por equipos y el mapeo del campo permiten generar información de forma continua, precisa y estandarizada. Esto permite analizar partidos con un nivel de detalle que sería prácticamente imposible de lograr de manera manual.

3.3.2. Impacto económico

Las herramientas comerciales que realizan análisis similares suelen estar dirigidas a contextos de élite y requieren inversiones significativas. Un sistema basado en modelos abiertos, entrenados y ajustados localmente, reduce la dependencia de proveedores externos y podría ser utilizado por clubes profesionales, semiprofesionales, escuelas deportivas e incluso proyectos de formación juvenil.

3.3.3. Impacto social

El fútbol es una actividad central en la vida de millones de personas en Colombia. Hacer accesible el análisis avanzado permite potenciar procesos de formación, identificar talento joven y brindar más oportunidades de desarrollo. Al permitir que instituciones con bajos recursos accedan a tecnología de punta, el sistema contribuye a cerrar brechas en la formación deportiva.

3.3.4. Impacto académico

La tesis aporta conocimiento nuevo sobre cómo integrar modelos de visión por computador de última generación en un ambiente real, con condiciones audiovisuales complejas. Además, genera una base para futuros trabajos relacionados con métricas avanzadas, análisis táctico automatizado, predicción de jugadas y aplicaciones multimodales.

3.3.5. Relevancia cultural

El deporte, y en particular el fútbol, como ya se mencionó anteriormente, tiene un impacto directo sociocultural. El permitir hacer mejores análisis, disminuir la subjetividad de los entrenadores y analistas, y poder brindar objetividad por medio de los datos, permite el crecimiento más imparcial y crítico de los jugadores en formación, brindándoles oportunidades más justas y meritocráticas.

Capítulo 4

MARCO TEÓRICO Y ESTADO DEL ARTE

4.1. Conceptos fundamentales

Antes de entrar a los modelos específicos, es importante dejar claras algunas ideas base que van a aparecer constantemente a lo largo de la tesis. La idea no es hacer un tratado teórico completo, sino fijar un lenguaje común para quien lea el documento, permitiéndonos así facilitar el entendimiento de ciertos conceptos y el uso de estos.

4.1.1. Visión por computador

Cuando hablamos de visión por computador nos referimos al conjunto de técnicas que permiten que una máquina “vea” o, más precisamente, que procese e interprete información a partir de imágenes o videos. En la práctica, esto implica transformar píxeles en representaciones numéricas que capturan bordes, texturas, formas, colores y, más recientemente, conceptos de más alto nivel como “jugador”, “balón”, “árbitro” o “líneas de campo”.

En esta tesis la visión por computador es el núcleo del sistema: todo lo demás (métricas, análisis, visualizaciones) depende de qué tan bien seamos capaces de detectar y seguir a los actores del partido a partir del video.

4.1.2. Aprendizaje profundo en visión: de las CNN a los transformadores

El salto grande en visión por computador vino con las redes neuronales profundas. Primero con las redes convolucionales (CNN), que aprendían filtros que se aplican sobre la imagen para detectar patrones locales; y más recientemente con arquitecturas basadas en transformadores, que permiten modelar relaciones más globales entre regiones de una imagen o entre fotogramas de un video.

Modelos como ResNet nacen del mundo de las CNN y siguen siendo muy útiles cuando queremos clasificar fragmentos de imagen, por ejemplo, un recorte del dorsal de un jugador. Por otro lado, familias como DETR y RF-DETR utilizan transformadores para resolver la detección de objetos de una forma más flexible y robusta, lo que las hace especialmente atractivas para escenarios complejos como el fútbol televisado.

En esta tesis usamos ambos mundos: CNN para tareas más clásicas (como clasificación de números) y transformadores para detección y segmentación.

4.1.3. Detección de objetos y detección de objetos pequeños

La detección de objetos consiste en localizar y clasificar instancias de interés dentro de una imagen, típicamente mediante cajas delimitadoras, llamadas *bounding boxes*. Para fútbol, los objetos clave son los jugadores, porteros, árbitros, el balón e incluso algunos elementos del campo como las porterías o las líneas.

El balón introduce un problema adicional: es un objeto pequeño, que usualmente se mueve rápido y que se pierde fácilmente por oclusiones, desenfoque o compresión del video. A esto se le conoce como detección de objetos pequeños, y suele requerir estrategias específicas, como modelos especializados, recortes locales del cuadro o aumentos de datos diseñados para resaltar detalles muy finos.

En nuestro repositorio VM_FOOTBALL se combinan ambas cosas: detección multiclase general y un modelo especializado para el balón.

4.1.4. Segmentación y seguimiento (Multi-Object Tracking)

Mientras la detección nos dice “dónde” hay un objeto en un fotograma, la segmentación busca separar los píxeles que pertenecen al objeto del resto de la imagen o del resto de los objetos. Esto permite tener una máscara mucho más precisa que una simple caja, teniendo así una precisión más alta cuando varios objetos (jugadores, balón, jueces, etc.) se muestran a la vez en pantalla.

El seguimiento o *Multi-Object Tracking* (MOT) añade la dimensión temporal: el objetivo es mantener la identidad de cada jugador o del balón a lo largo de toda la secuencia de video, enlazando detecciones cuadro a cuadro para formar trayectorias. En el contexto de SoccerNet-Tracking, por ejemplo, se anotan jugadores, balón y árbitros a lo largo de cientos de clips y al menos medio tiempo completo de partido, precisamente para evaluar este tipo de algoritmos. En esta tesis, el seguimiento se apoya en modelos de segmentación fundacionales como SAM2, que permiten seguir objetos de forma más estable a lo largo del tiempo.

4.1.5. Modelos de visión–lenguaje

Los modelos de visión–lenguaje son arquitecturas que procesan conjuntamente imágenes y texto. En lugar de limitarse a decir “aquí hay un jugador”, pueden responder a preguntas, generar descripciones o producir representaciones que alinean conceptos visuales y palabras en un mismo espacio de características.

4.2. Visión por computador en el fútbol profesional: de los estadios de élite a la señal de TV

Ejemplos recientes son SmolVLM y SmolVLM2, modelos compactos que permiten hacer *captioning*, responder preguntas sobre una imagen o extraer información textual (como el número de una camiseta) con un costo computacional relativamente bajo.

Ligado a esto están modelos como SigLIP y SigLIP2, que son codificadores visión–lenguaje capaces de mapear imágenes y texto a un espacio vectorial compartido, optimizado para clasificación *zero-shot*, recuperación imagen–texto y uso como extractor de *embeddings* visuales. SigLIP2 incorpora estrategias como preentrenamiento con *captioning*, pérdidas auto-supervisadas y curación en línea de datos, logrando mejoras consistentes frente a su versión original.

En este trabajo, estos modelos se utilizan principalmente para dos cosas: apoyar la lectura de dorsales y construir representaciones que permitan agrupar jugadores por uniformes.

4.1.6. *Clustering* y espacios de representación

El *clustering* es una familia de métodos no supervisados cuyo objetivo es agrupar datos similares sin que existan etiquetas previas. El algoritmo K-means, que es el que usaremos, parte de un número de clústeres predefinido (en nuestro caso, será dos debido a la cantidad de equipos en el campo) y busca repartir los puntos de manera que cada grupo quede lo más compacto posible.

La clave está en qué representación usamos como entrada. En lugar de trabajar solo con valores de color, en VM_FOOTBALL utilizamos *embeddings* generados por un modelo de visión–lenguaje como SigLIP2. De esta forma, los clústeres no solo capturan diferencias cromáticas, sino también patrones semánticos y de textura que ayudan a separar mejor los equipos, incluso cuando los uniformes o la iluminación no son ideales.

4.2. Visión por computador en el fútbol profesional: de los estadios de élite a la señal de TV

En las grandes ligas europeas el problema que queremos resolver ya tiene soluciones muy sofisticadas, pero casi siempre bajo condiciones que están lejos de la realidad latinoamericana. Hoy, la mayoría de ligas de primer nivel trabajan con sistemas de *tracking* instalados en los estadios, con arreglos de múltiples cámaras de alta definición y hardware dedicado solo a capturar la posición de jugadores y balón en cada instante del partido.

Un ejemplo clásico es TRACAB, sistema óptico que se ha convertido en estándar en ligas como la *Premier League*, *LaLiga* y la *Bundesliga*, así como en varias competiciones UEFA y FIFA. Estos sistemas montan pares de cámaras estereoscópicas alrededor del estadio, capturan la escena a unas 25 imágenes por segundo y reconstruyen en tiempo real las coordenadas x , y , z de todos los jugadores, árbitros y el balón. La salida es un “*feed*” estructurado con millones de puntos de datos por partido, que luego se usa para métricas físicas, análisis táctico y productos audiovisuales.

En paralelo, en los últimos años han aparecido soluciones comerciales basadas en visión por computador que trabajan directamente sobre la señal de TV o una sola cámara táctica.

SkillCorner, por ejemplo, ofrece *tracking* automático de jugadores y balón a partir de cualquier cámara única, incluyendo la señal de transmisión. Su propuesta consiste justamente en extraer coordenadas 2D de jugadores y 3D del balón con modelos de *deep learning* entrenados sobre grandes volúmenes de video de ligas profesionales.

Otra pieza importante en el ecosistema actual es *StatsBomb 360*, un producto de datos que registra, para cada evento del partido, la posición de todos los jugadores que aparecen en el cuadro en ese instante, generando lo que llaman “*freeze frames*”. Este tipo de datos se obtiene combinando detección de jugadores, calibración del campo y anotación asistida para dejar un “*snapshot*” rico alrededor de cada pase o tiro.

En términos de tecnología subyacente, muchos de estos proveedores no publican sus arquitecturas exactas, pero hay un patrón claro: modelos de detección y segmentación basados en CNN y transformadores, *pipelines* de *tracking* multiobjeto y módulos de calibración geométrica del campo para proyectar todo a coordenadas físicas. En otras palabras, la lógica de “detectar, seguir, proyectar y analizar” ya está muy consolidada en los estadios de élite, pero dentro de infraestructuras propietarias, costosas y poco documentadas.

En Latinoamérica la foto es diferente. Existen proveedores globales que pueden ofrecer datos a partir de la señal de TV (*SkillCorner*, *Hudl/StatsBomb*, etc.), pero hay poca documentación pública de proyectos que usen directamente la señal de ligas como la colombiana para construir *pipelines* abiertos de análisis táctico. La información disponible sobre canales de televisión deportiva se centra principalmente en la infraestructura de producción (ingesta, edición, distribución de señales), no en sistemas de seguimiento automático encima de la señal.

Esto deja un vacío claro: sabemos que las grandes ligas ya usan visión por computador y sistemas de *tracking* a gran escala, pero no hay trabajos abiertos que documenten cómo llevar esos avances a contextos donde solo se tiene acceso a la señal televisiva y a grabaciones de entrenamientos, como ocurre en gran parte del fútbol colombiano y formativo.

4.3. Datasets para visión por computadora en fútbol

El desarrollo de sistemas de visión por computadora aplicados al fútbol depende críticamente de la disponibilidad de *datasets* anotados que capturen la complejidad visual del dominio. En esta sección se revisan los principales *datasets* públicos para seguimiento de objetos múltiples (MOT) en fútbol, estableciendo el contexto académico necesario para justificar las decisiones metodológicas del proyecto.

4.3.1. SoccerNet-Tracking: el benchmark estándar

SoccerNet-Tracking (también conocido como *SoccerNet-MOT*) es actualmente el *dataset* de seguimiento de objetos múltiples más grande disponible públicamente en el dominio deportivo, específicamente para fútbol. Fue introducido en CVPR 2022 Workshop on Computer Vision for Sports (CVSports) como parte de la familia SoccerNet, una iniciativa de investigación que ha establecido múltiples benchmarks para análisis de video de fútbol.

El *dataset* está compuesto por 200 secuencias de 30 segundos cada una, seleccionadas para representar escenarios desafiantes del fútbol profesional europeo, además de incluir un tiempo completo de 45 minutos para evaluación de seguimiento a largo plazo. Esta estructura permite entrenar y evaluar tanto la robustez puntual (secuencias cortas con situaciones complejas) como la consistencia temporal extendida (medio tiempo completo).

Cada secuencia está completamente anotada con cajas delimitadoras (*bounding boxes*) e identificadores de trayectoria (*tracklet IDs*) para ocho clases de objetos: jugador equipo izquierdo, jugador equipo derecho, portero equipo izquierdo, portero equipo derecho, árbitro principal, árbitro lateral, personal técnico y balón. Con más de 200,000 anotaciones de *bounding boxes* distribuidas en 12 partidos completos filmados desde cámara principal a 1080p, el *dataset* supera significativamente en volumen a alternativas previas en el dominio deportivo.

Las anotaciones siguen los estándares rigurosos del dominio de MOT, lo que facilita el entrenamiento de modelos supervisados y la evaluación mediante métricas consolidadas. El benchmark oficial utiliza HOTA (Higher Order Tracking Accuracy) como métrica principal, que descompone el desempeño en precisión de detección (DetA) y precisión de asociación (AssA), permitiendo diagnósticos detallados sobre qué componente del sistema de seguimiento requiere mejoras.

SoccerNet-Tracking se ha consolidado como el estándar de facto para evaluar sistemas de seguimiento en fútbol, con desafíos anuales organizados por la comunidad académica en conferencias como CVPR. Esta estandarización permite comparar el desempeño de nuevos métodos frente a líneas base publicadas y asegurar que las contribuciones sean medibles, reproducibles y comparables.

Las secuencias incluyen situaciones complejas típicas del fútbol profesional: movimientos rápidos de jugadores, oclusiones severas (jugadores superpuestos o parcialmente fuera de cuadro), cambios bruscos de iluminación (sombras en estadios al aire libre), compresión de video típica de transmisiones broadcast, y objetos pequeños (especialmente el balón, que puede ocupar menos del 1 % del área de la imagen). Esta diversidad de escenarios prepara a los modelos para condiciones reales, reduciendo el riesgo de sobreajuste a entornos controlados.

4.3.2. **Datasets alternativos y comparación**

Aunque SoccerNet-Tracking domina el panorama académico actual, existen otros *datasets* relevantes que abordan aspectos específicos del análisis de fútbol mediante visión por computadora:

TeamTrack es un *dataset* extenso de video de cancha completa para múltiples deportes, incluyendo fútbol, baloncesto y balonmano. Su fortaleza radica en la diversidad multi-deporte y en la captura de vista cenital completa del campo, lo que facilita proyecciones geométricas. Sin embargo, carece de la profundidad de anotaciones específicas del fútbol que ofrece SoccerNet-Tracking, como diferenciación entre porteros y jugadores de campo, seguimiento del balón con granularidad equivalente, o anotaciones de árbitros y personal técnico. Para proyectos centrados exclusivamente en fútbol con múltiples clases de actores, TeamTrack resulta menos específico.

ISSIA es un *dataset* compuesto por 15,707 imágenes anotadas de jugadores y balones, útil para entrenar detectores de objetos en contexto futbolístico. Su principal limitación es la ausencia de información temporal: al ser un conjunto de imágenes estáticas sin *tracklet IDs* ni secuencias de video, no permite entrenar ni evaluar algoritmos de seguimiento (MOT). ISSIA es valioso como complemento para aumentar la diversidad de ejemplos de detección, pero insuficiente como único *dataset* para sistemas de seguimiento temporal.

SoccerSynth-Detection representa el primer *dataset* sintético para detección de jugadores de fútbol, generado mediante motores de renderizado 3D. Los resultados experimentales reportados muestran que modelos entrenados en este *dataset* sintético logran mejor generalización en presencia de *motion blur* comparado con aquellos entrenados exclusivamente en datos reales. Esta capacidad de mitigar problemas de desenfoco por movimiento es prometedora, especialmente en transmisiones con alta velocidad de acción. Sin embargo, SoccerSynth-Detection aún requiere validación extensa en escenarios reales diversos y no reemplaza la complejidad visual completa de videos broadcast: variaciones de iluminación natural, texturas de césped real, publicidad dinámica en vallas, y artefactos de compresión propios de señales televisivas. Su uso óptimo es como complemento sintético a *datasets* reales, no como sustituto.

Otros *datasets* mencionados en la literatura reciente incluyen **SoccerTrack** (enfocado en videos con cámara ojo de pez y drones), y benchmarks más amplios como **SportsMOT**, que agregan múltiples deportes pero diluyen la especificidad del fútbol. Ninguno de estos combina la escala, especificidad al fútbol y riqueza de anotaciones temporales de SoccerNet-Tracking.

4.3.3. Limitaciones de los datasets existentes para el contexto latinoamericano

Un aspecto crítico que ninguno de los *datasets* académicos actuales aborda adecuadamente es la diversidad de condiciones de producción audiovisual fuera de ligas europeas de élite. SoccerNet-Tracking, TeamTrack, ISSIA y SoccerSynth-Detection fueron creados con material de ligas profesionales de alto nivel (principalmente europeas) donde la calidad de producción es homogénea: iluminación de estadios estandarizada, cámaras de alta definición, transmisiones con baja compresión y ángulos consistentes.

En contraste, el fútbol latinoamericano (y específicamente colombiano) presenta características visuales distintas: variabilidad mayor en calidad de compresión de video, estilos de uniformes con mayor presencia publicitaria, iluminación de estadios más pequeños (con sombras más pronunciadas o iluminación artificial desigual), y ángulos de cámara menos estandarizados. Estas diferencias de dominio pueden degradar significativamente el desempeño de modelos entrenados exclusivamente en *datasets* europeos.

Esta brecha entre los *datasets* disponibles y las condiciones reales del fútbol colombiano justifica la estrategia metodológica de *domain adaptation* mediante *fine-tuning* con material audiovisual local, que se detalla en el Capítulo 5. Los *datasets* académicos proporcionan la base de conocimiento (volumen, diversidad de escenarios, anotaciones de calidad), pero deben ser complementados con datos del dominio objetivo para lograr generalización robusta.

4.4. Modelos de última generación elegidos para VM_FOOTBALL

A partir de ese panorama, la tesis no intenta replicar un *TRACAB* de estadio ni competir con proveedores comerciales, sino construir un *pipeline* abierto que se pueda reentrenar, desplegar y entender. Eso implica escoger modelos que estén cerca del estado del arte, pero que además cumplan tres requisitos prácticos: pesos abiertos, licencia razonable y capacidad real de *fine-tuning* con datos locales.

En esta sección se profundiza en los modelos que se escogieron y en por qué se eligieron frente a sus alternativas.

4.4.1. RF-DETR: detección basada en transformadores en tiempo real

RF-DETR es un modelo de detección desarrollado por Roboflow como una versión *real-time* de la familia DETR, con licencia Apache 2.0. Está pensado para transferirse bien a muchos dominios distintos, soportar *datasets* grandes y pequeños, y funcionar en tiempo real.

Arquitectónicamente, RF-DETR combina:

- Un *backbone* visual tipo *DINOv2*, que actúa como extractor de características potente y preentrenado de forma autosupervisada.
- Un *encoder-decoder* tipo *transformer* que trabaja sobre un conjunto de “*queries* de objeto”, es decir, vectores que representan posibles objetos en la imagen.
- Un módulo de selección de *queries* y una cabeza de predicción que generan para cada objeto detectado su clase y su caja delimitadora.

El entrenamiento se realiza con una pérdida de tipo *Hungarian matching*: para cada imagen, el modelo genera un conjunto fijo de predicciones, y luego se resuelve un problema de asignación óptima entre esas predicciones y los objetos reales, minimizando una combinación de pérdida de clasificación y pérdida de localización (por ejemplo, distancia L1 e $1 - \text{IoU}$). Esto obliga al modelo a aprender a producir un conjunto de objetos sin depender de *Non-Maximum Suppression*, lo que simplifica el *pipeline* en inferencia y reduce latencias.

En comparaciones recientes, RF-DETR alcanza más de 60 mAP en COCO manteniendo velocidades de inferencia cercanas a las de detectores tipo YOLO modernos, y en algunos escenarios llega a superarlos en precisión mientras se mantiene competitivo en FPS. Esto lo hace especialmente atractivo en un contexto como el nuestro, donde se quiere trabajar con video y no solo con imágenes estáticas.

En VM_FOOTBALL RF-DETR se usa como “puerta de entrada” del sistema: localiza jugadores, porteros, árbitros y balón en cada fotograma. Se eligió por tres razones: (i) es SOTA dentro de los detectores en tiempo real de código abierto, (ii) está diseñado explícitamente para adaptarse bien a dominios nuevos con poco dato y (iii) su formulación con transformadores encaja bien con secuencias de video donde hay mucha variación de contexto entre cuadros.

4.4.2. SAM2: segmentación fundacional con memoria para video

Segment Anything Model 2 (SAM2) es la evolución del SAM original propuesto por Meta. El objetivo de SAM era “segmentar cualquier cosa” a partir de señales como puntos, cajas o trazos. SAM2 extiende esa idea a video, incorporando un mecanismo de memoria en flujo (*streaming memory*) que le permite seguir máscaras en secuencias largas y mantener consistencia temporal.

A alto nivel, SAM2 tiene tres bloques importantes:

- Un *encoder* de imagen que produce un mapa de características denso.
- Un *encoder* de entradas (en el diseño original, los *prompts*; en nuestro caso, las cajas de RF-DETR) que genera representaciones de los objetos a segmentar.
- Un decodificador de máscaras que, apoyado en la memoria temporal, devuelve máscaras precisas cuadro a cuadro y actualiza el estado para el siguiente fotograma.

En esta tesis, SAM2 no se usa de forma interactiva, sino como segmentador ajustado a nuestro dominio y guiado automáticamente por las cajas de RF-DETR. Se parte de los pesos preentrenados abiertos y se hace *fine-tuning* sobre un subconjunto de datos anotados con máscaras para tres clases: jugadores, árbitros y balón, mezclando ejemplos de SoccerNet con clips de televisión colombiana y fútbol formativo.

Matemáticamente, el entrenamiento de SAM2 consiste en minimizar pérdidas de segmentación (por ejemplo, combinación de *Binary Cross-Entropy* e IoU) entre las máscaras predichas y las máscaras anotadas, mientras la memoria aprende a propagar identidades en el tiempo. La idea es que, dado un fotograma I_t , las cajas de RF-DETR activen ciertos “*tokens* de objeto” y el decodificador produzca máscaras M_t^k coherentes con las de instantes anteriores M_{t-1}^k , incluso con oclusiones parciales.

Frente a alternativas clásicas de MOT basadas en detección + asociación con *Kalman filters* y distancias en el espacio de apariencias, SAM2 tiene una ventaja clara: la máscara aporta mucha información geométrica y de forma que ayuda a mantener identidades incluso cuando hay choques, agrupamientos o cambios de escala muy bruscos. Eso es exactamente lo que pasa todo el tiempo en un partido.

4.4.3. SmolVLM2 como motor de OCR flexible

Para la lectura de dorsales el problema no es solo “ver un número”, sino verlo con ángulos raros, tipografías distintas, publicidad encima y compresión de video. Tradicionalmente esto se abordaba con modelos CNN+RNN y pérdidas tipo CTC, diseñados específicamente para OCR. Hoy hay otra opción: modelos visión–lenguaje compactos que entienden texto dentro de imágenes y video.

SmolVLM y su sucesor **SmolVLM2** son modelos multimodales compactos diseñados para ser eficientes y abiertos. Están contruidos como un *encoder* de visión (en varias configuraciones, muchas veces usando SigLIP como base) acoplado a un modelo de lenguaje SmolLM2, y se

entrenan sobre tareas de *captioning*, *VQA* y comprensión de video bajo restricciones fuertes de memoria y cómputo.

En términos muy simplificados, SmolVLM2 aprende una función

$$f_{\theta}(\text{imagen}) \rightarrow \text{texto},$$

donde la optimización se hace sobre pérdidas de lenguaje (por ejemplo, *cross-entropy token* a *token*) condicionadas por los *tokens* visuales. La gracia está en que esa función puede adaptarse a muchas tareas distintas cambiando solo el *prompt* o el *fine-tuning*, sin rediseñar toda la arquitectura.

En VM_FOOTBALL SmolVLM2 se usa sobre recortes que contienen la zona del dorsal. En lugar de limitarse a un OCR clásico, se aprovecha su capacidad de “leer” números bajo variaciones fuertes: se le pide que proponga un número de camiseta probable y se combina su salida con la de una red más rígida (ResNet) para estabilizar la decisión. La motivación de usar SmolVLM2 y no un modelo gigante es pragmática: es suficientemente pequeño para correr en hardware moderado, tiene pesos abiertos y está optimizado justo para este tipo de tareas visión–texto.

4.4.4. ResNet como clasificador de dígitos de camiseta

Aunque SmolVLM2 ya puede leer números, la experiencia muestra que combinar un modelo generativo con uno discriminativo ayuda a reducir errores raros. Ahí entra **ResNet**, una familia de redes convolucionales profundas con conexiones residuales que facilitan el entrenamiento de redes muy profundas sin problemas fuertes de degradación.

ResNet, en su forma básica, implementa bloques de la forma

$$\mathbf{y} = F(\mathbf{x}, W) + \mathbf{x},$$

donde F es una secuencia de convoluciones, normalización y activaciones, y $\mathbf{x}$ es el “atajo” que se suma a la salida. Esta estructura hace que la red aprenda “correcciones” sobre la identidad, en lugar de mapas completamente nuevos, lo que estabiliza la optimización.

En esta tesis, una variante pequeña de ResNet se reentrena específicamente para clasificar dígitos de dorsal (0–99) en recortes ya segmentados. La pérdida es la usual de clasificación (*cross-entropy*) sobre las clases de número, y el objetivo es que actúe como “filtro de sanidad”: si SmolVLM2 propone un número pero la probabilidad de ResNet para esa clase es muy baja, el sistema puede marcar la lectura como dudosa o revisar las predicciones vecinas.

Se eligió ResNet y no arquitecturas más recientes de clasificación porque el problema es relativamente clásico, el tamaño de los recortes es pequeño y las implementaciones de ResNet están muy probadas y optimizadas.

4.4.5. SigLIP2 como generador de *embeddings* para equipos

Para separar jugadores por equipo no basta con mirar colores “a ojo”, sobre todo cuando los uniformes no son tan contrastados o la iluminación es irregular. Necesitamos representaciones robustas de parches de uniforme. Ahí entra **SigLIP2**.

El punto de partida es SigLIP, un esquema de preentrenamiento visión–lenguaje que modifica el contraste clásico de CLIP. En vez de usar una pérdida *softmax* que compara cada par imagen–texto con todos los demás pares del *batch*, SigLIP formula el problema como una colección de tareas binarias independientes, usando una pérdida sigmoideal por par. Eso permite escalar a *batches* grandes y mejora la estabilidad en tamaños más pequeños.

SigLIP2 da un paso adicional: combina el objetivo original de imagen–texto con preentrenamiento basado en *captioning* mediante un decodificador auxiliar, pérdidas autosupervisadas (autodestilación, enmascaramiento) y curación en línea de datos. El resultado son *encoders* visión–lenguaje multilingües con mejor entendimiento semántico, mejor localización y mejores características densas para tareas de segmentación o detección.

Matemáticamente, la parte de imagen–texto sigue el espíritu del contraste, pero con una pérdida tipo

$$\ell(\mathbf{v}, \mathbf{t}) = - \left[y \log \sigma(\mathbf{v}^\top \mathbf{t}) + (1 - y) \log(1 - \sigma(\mathbf{v}^\top \mathbf{t})) \right],$$

donde $\mathbf{v}$ y $\mathbf{t}$ son los *embeddings* de imagen y texto, σ es la sigmoide y y indica si el par es positivo o negativo.

En nuestro caso no nos interesa tanto el texto, sino las representaciones visuales que salen del *encoder*. Esos *embeddings* son los que alimentan K-means para agrupar jugadores en dos clústeres que corresponden a los equipos. La razón de escoger SigLIP2 sobre alternativas como CLIP o simples histogramas de color es doble:

- Está entrenado para ser robusto a cambios de iluminación, ruido y variaciones de dominio, algo crucial en transmisiones con calidad variable.
- Produce *embeddings* que capturan patrones de textura, logo, diseño del uniforme y no solo color plano, lo que ayuda cuando los dos equipos usan colores parecidos o cuando las camisetas tienen mucho patrocinio.

4.4.6. 4.3.6. Modelos especializados para el balón y detección de objetos pequeños

El balón, por tamaño y velocidad, se comporta como un “caso extremo” de detección de objeto pequeño. La literatura reciente en detección ha señalado que, incluso en modelos SOTA, los objetos pequeños sufren: aportan pocos píxeles, son más sensibles a *blur* y compresión, y tienden a perderse cuando la red reduce la resolución espacial demasiado rápido.

RF-DETR, al apoyarse en *backbones* como DINOv2 y en atención global, ya mejora a versiones anteriores de RT-DETR en detección de objetos pequeños, pero aun así es común apoyarse en modelos específicos para deportes, entrenados con más énfasis en el balón y estrategias como recortes locales o pirámides de resolución.

En esta tesis se plantea usar un modelo especializado de balón entrenado en plataformas como Roboflow (por ejemplo, variantes del modelo *football-ball-detection*) como punto de partida, y combinarlo con estrategias de subdivisión de imagen: dividir el cuadro en subregiones, aplicar el detector sobre cada una y volver a ensamblar las detecciones. Esto, en la práctica, aumenta la resolución efectiva con la que la red “ve” el balón.

La motivación de tener un modelo dedicado es simple: en términos de análisis táctico, perder el balón en el *tracking* es mucho más grave que perder un jugador durante uno o dos cuadros. Por eso tiene sentido sobredimensionar un poco la solución para este objeto concreto.

4.5. 4.4. Modelos y metodologías en ligas de élite vs. contexto latinoamericano

Si miramos el ecosistema completo, se pueden distinguir dos grandes familias de soluciones:

- **Sistemas de estadio multicámara**, como TRACAB o Second Spectrum, instalados físicamente en ligas como Premier League, Bundesliga, LaLiga, MLS o Ekstraklasa. Estos sistemas combinan arreglos de cámaras calibradas, reconstrucción 3D y algoritmos de *tracking* de alta precisión aprobados por programas FIFA de EPTS.
- **Soluciones de *tracking* a partir de señal de TV**, como SkillCorner o los productos de Hudl/StatsBomb, que aplican modelos de visión por computador sobre la transmisión para generar datos posicionales y contextuales sin necesidad de hardware en el estadio.

En ambos casos se trata de *pipelines* avanzados donde la detección, el seguimiento y la proyección al campo ya están muy optimizados, pero son soluciones propietarias, cerradas y adaptadas a contextos donde la calidad de producción es alta y relativamente homogénea.

En Colombia y buena parte de Latinoamérica, en cambio, la realidad es otra. Los clubes y escuelas de formación suelen trabajar con:

- Grabaciones de televisión con niveles de compresión variables.
- Videos de cámara única en entrenamientos o torneos juveniles.
- Recursos limitados para contratar proveedores internacionales de datos.

No hay, hasta donde llega la revisión bibliográfica y técnica, un proyecto abierto que documente de forma detallada un *pipeline* moderno basado en RF-DETR, SAM2, SigLIP2, SmolVLM2 y modelos especializados de balón aplicado a fútbol colombiano. La mayoría de análisis se hacen todavía de forma manual o con herramientas comerciales que no exponen sus modelos ni permiten reentrenar con datos locales.

Justamente ahí se ubica esta tesis: toma ideas probadas en grandes ligas (*detection-tracking-projection* sobre video) y las reinterpreta con modelos de última generación y pesos abiertos, buscando que el resultado sea replicable y ajustable en entornos con menos infraestructura.

4.6. 4.5. Conclusión del estado del arte y marco teórico

La elección de modelos en VM_FOOTBALL no es solo una lista de nombres “de moda”, sino una respuesta directa a los retos identificados:

- **Necesidad de detección robusta en video real:** RF-DETR aporta un detector en tiempo real, basado en transformadores, con buen rendimiento en objetos pequeños y fácil de ajustar a un nuevo dominio.
- **Necesidad de trayectorias estables y segmentación fina:** SAM2 introduce una capa fundacional de segmentación con memoria temporal, que permite seguir jugadores y balón con máscaras consistentes y no solo con cajas.
- **Necesidad de identificar jugadores y equipos, no solo “personas” genéricas:** SmolVLM2 y ResNet se combinan para leer dorsales en condiciones difíciles; SigLIP2 genera *embeddings* ricos de uniformes, que K-means convierte en grupos coherentes sin etiquetado manual.
- **Necesidad de cuidados especiales para el balón:** un modelo especializado de balón, combinado con estrategias de recorte, fortalece la parte más delicada del *tracking* desde la perspectiva táctica.

En conjunto, estos modelos permiten construir un *pipeline* que se parece conceptualmente a lo que hacen los grandes proveedores (detectar, seguir, identificar, proyectar), pero con una diferencia clave: todo se apoya en arquitecturas abiertas que se pueden reentrenar con material de ligas colombianas, semiprofesionales o de formación.

Esta conexión entre estado del arte y metodología es la que le da sentido a la tesis: no se trata solo de aplicar modelos modernos a un *dataset* público, sino de usar esos modelos como “bloques de construcción” para cerrar una brecha concreta entre la tecnología disponible en el fútbol de élite y lo que se puede hacer, de forma realista, con la señal de televisión y las grabaciones que sí están al alcance de clubes, escuelas y analistas en Colombia.

Capítulo 5

METODOLOGÍA

5.1. Enfoque general

La tesis se plantea como un trabajo cuantitativo, experimental y aplicado. Más que entrenar modelos por separado, la idea es construir un sistema completo que reciba un video de un partido de fútbol y lo convierta en información estructurada sobre jugadores, balón y equipos, pensando siempre en escenarios reales: televisión colombiana y fútbol formativo o semiprofesional.

Metodológicamente el proyecto se apoya en un ciclo bastante claro. Primero se integran y limpian los datos, luego se entrenan y ajustan los modelos de detección, después se añade la capa de segmentación y seguimiento, más adelante se incorpora el reconocimiento de dorsales y el agrupamiento por equipos, y todo esto se evalúa de forma sistemática para ir refinando el *pipeline*. No es una secuencia rígida, sino un proceso iterativo donde los resultados de cada etapa alimentan decisiones en las siguientes.

5.2. Selección de modelos y arquitectura del sistema

El sistema propuesto integra seis arquitecturas complementarias: RF-DETR (detección en tiempo real), SAM2 (segmentación con memoria temporal), SmolVLM2 (reconocimiento de dorsales mediante visión-lenguaje), ResNet (clasificación de dígitos), SigLIP2 (*embeddings* visuales para clustering) y un modelo especializado para detección del balón. La fundamentación teórica, formulación matemática y justificación académica de cada modelo se presentan en detalle en la Sección 4.3 del Marco Teórico. Esta selección responde a requisitos técnicos específicos del proyecto: (i) detección robusta en tiempo real compatible con procesamiento de video broadcast, (ii) seguimiento estable de múltiples objetos con oclusiones severas, (iii) identificación de jugadores mediante dorsales bajo condiciones visuales adversas, (iv) agrupamiento automático por equipos sin etiquetado manual, y (v) tratamiento especializado del balón como objeto pequeño crítico para el análisis táctico. Todos los modelos seleccionados cumplen tres criterios prácticos: pesos abiertos, licencias permisivas y capacidad de ajuste fino con datos locales del contexto colombiano.

5.3. Flujo del sistema

El punto de partida de la metodología es tener claro cómo se espera que funcione el sistema cuando esté armado. La historia es más o menos así: partimos de un video de entrada que puede venir del *dataset SoccerNet-MOT*, de una transmisión de televisión colombiana o de una grabación de entrenamiento o fútbol semiprofesional. Ese video se normaliza a una resolución y a una frecuencia de cuadros fija, y se descompone en fotogramas sobre los que van a trabajar los modelos.

En cada fotograma, **RF-DETR** actúa como detector principal. Este modelo se encarga de localizar jugadores, porteros, árbitros y balón, asignándoles una categoría y una caja con coordenadas y probabilidades asociadas. A partir de estas detecciones entra el segundo componente clave, **SAM2**, que ya no se usa de forma interactiva, sino ajustado como segmentador para este dominio. SAM2 toma el fotograma junto con la información de las detecciones de RF-DETR y produce máscaras más precisas para cada instancia, además de mantener una memoria temporal que ayuda a seguir a esos mismos jugadores y al balón a lo largo de la secuencia. Con esto se construyen trayectorias más estables, incluso cuando alguna detección puntual se pierde o baja de confianza.

Sobre las secuencias ya estabilizadas con SAM2 se generan recortes específicos de dos tipos: por un lado, regiones donde debería aparecer el dorsal del jugador y, por otro, áreas donde el uniforme es claramente visible. Los recortes de dorsal alimentan el módulo de reconocimiento de números, que combina un modelo multimodal como **SmoIvLM2** con una red tipo **ResNet** reentrenada para clasificar dígitos del 0 al 99. Los recortes de uniforme se pasan por un codificador visión-lenguaje como **SigLIP2**, que devuelve *embeddings* que capturan el estilo visual del equipo. Esos vectores sirven como base para el agrupamiento posterior en equipos mediante **K-means**, apoyado cuando hace falta con descriptores de color HSV para reforzar la separación.

El resultado final del *pipeline* es una estructura de datos en la que, para cada jugador, se dispone de una trayectoria, un dorsal estimado y una etiqueta de equipo, junto con la trayectoria del balón y la información necesaria para proyectar todo sobre una representación del campo. Esta representación es la que, más adelante, puede alimentar análisis tácticos, métricas de rendimiento o una futura plataforma interactiva orientada a entrenadores y analistas.

5.4. Datos y contexto de entrenamiento

5.4.1. Selección del dataset base y estrategia de adaptación

Para este proyecto se utiliza *SoccerNet-Tracking* como *dataset* base de entrenamiento. La descripción académica completa del *dataset*, su comparación con alternativas (TeamTrack, ISSIA, SoccerSynth-Detection) y las limitaciones de los *datasets* existentes para el contexto latinoamericano se presentan en la Sección 4.2.3 del Marco Teórico. La selección de SoccerNet-Tracking responde a tres criterios fundamentales: (i) es el *dataset* de MOT más grande en el dominio del fútbol, con más de 200,000 anotaciones en 12 partidos completos;

(ii) provee anotaciones multiobjeto detalladas (8 clases: jugadores, porteros, árbitros, personal, balón) con *tracklet IDs* que permiten entrenar seguimiento temporal; y (iii) constituye el benchmark estándar de la comunidad académica, permitiendo comparación directa con métodos estado del arte.

Sin embargo, como se discute en la Sección 4.2.3, los *datasets* académicos fueron creados con material de ligas europeas de élite, donde las condiciones de producción audiovisual son homogéneas y de alta calidad. En contraste, el contexto colombiano presenta características visuales distintas: mayor variabilidad en compresión de video, uniformes con presencia publicitaria más prominente, iluminación de estadios más pequeños, y ángulos de cámara menos estandarizados.

Esta brecha de dominio motiva la estrategia metodológica central del proyecto: entrenar inicialmente con SoccerNet-Tracking para aprovechar su volumen y diversidad de escenarios, y posteriormente realizar *fine-tuning* sistemático con material audiovisual colombiano (transmisiones de Win Sports en YouTube, grabaciones de fútbol formativo y semiprofesional). Esta estrategia de *domain adaptation* supervisada permite que los modelos aprendan las particularidades visuales del contexto objetivo sin perder las representaciones robustas adquiridas en el *dataset* base.

5.4.2. Organización y procesamiento de los datos

El primer bloque de trabajo consiste en asegurar que los modelos vean datos variados, pero al mismo tiempo coherentes con la realidad a la que se quiere llegar. Por eso se parte de *SoccerNet-MOT* y, en particular, de su componente de *tracking*, que ofrece partidos profesionales europeos con anotaciones detalladas de jugadores, balón y árbitros. Estas anotaciones se convierten a un formato uniforme compatible con RF-DETR y con el resto del *pipeline*, de manera que no haya fricción entre lo que produce el *dataset* y lo que espera el modelo.

Sobre esa base “limpia” se empieza a introducir el contexto que realmente interesa: televisión colombiana y fútbol de formación o semiprofesional. Aquí la metodología es un poco más artesanal. Se seleccionan fragmentos de partidos, sobre todo jugadas de gol, secuencias ofensivas, transiciones y acciones defensivas. Estos clips se segmentan, se revisan y se van anotando progresivamente, comenzando por cajas para jugadores y balón en una cantidad manejable de cuadros. La idea es ir construyendo un subconjunto local que sirva tanto para ajuste fino como para evaluar hasta qué punto el modelo generaliza fuera del entorno europeo de SoccerNet.

En paralelo, se construye un subconjunto específico para el balón. Este objeto, por su tamaño y velocidad, requiere un tratamiento especial. La estrategia prevista combina dos ideas: subdividir las imágenes en regiones para “acercarse” digitalmente al balón y aprovechar modelos especializados entrenados en plataformas como Roboflow para esta tarea. Estos modelos sirven como punto de partida y se adaptan en la medida en que se disponga de más ejemplos anotados en contextos colombianos.

5.5. Entrenamiento y ajuste de los modelos de detección

Con los datos organizados, la siguiente etapa es entrenar y ajustar los modelos de detección. RF-DETR se entrena primero con SoccerNet, para aprovechar un volumen grande de ejemplos ya anotados. En esta fase inicial el objetivo es lograr un modelo sólido en términos de **mAP**, precisión y *recall*, sin obsesionarse todavía con los detalles de la televisión colombiana.

Una vez alcanzado un desempeño estable en el dominio original, se pasa a la etapa de ajuste fino. Aquí se mezclan las muestras de televisión colombiana y de fútbol formativo con una fracción de datos europeos, de forma que el modelo no olvide lo que ya sabe, pero se vea forzado a adaptarse a las nuevas condiciones de iluminación, uniformes y compresión del video. Este ajuste se controla con un conjunto de validación propio del contexto colombiano, lo cual permite ver si realmente hay ganancia al especializar el modelo en este tipo de señal. En paralelo, se entrena y evalúa el modelo especializado del balón. La metodología contempla comparar la salida de RF-DETR frente al modelo centrado en el balón en escenarios complejos, por ejemplo, cuando el balón pasa cerca de anuncios, se confunde con animaciones o propaganda, o se pierde casi por completo en la gradación de pasto y sombra. Dependiendo de los resultados, se decide si el sistema final se queda solo con RF-DETR, solo con el modelo especializado o con una combinación que priorice uno u otro según la confianza.

5.6. Segmentación y seguimiento con SAM2

Cuando la detección es razonablemente buena, la siguiente capa del sistema es la segmentación y el seguimiento. En este punto, **SAM2** deja de entenderse como un modelo interactivo y se utiliza como un segmentador entrenado específicamente para nuestro dominio, guiado por las cajas que produce el detector. La idea es aprovechar sus pesos preentrenados como punto de partida, pero ajustar su cabeza de segmentación y los componentes necesarios para que aprenda a distinguir únicamente aquello que nos interesa: jugadores, árbitros y balón.

Metodológicamente esto implica construir un subconjunto de datos con máscaras anotadas para estas clases, combinando ejemplos de SoccerNet con secuencias provenientes de televisión colombiana y de fútbol formativo o semiprofesional. Con ese material se realiza un proceso de *fine-tuning* sobre SAM2, de forma que el modelo aprenda no solo a segmentar objetos genéricos, sino a hacerlo de manera consistente en el contexto visual concreto del fútbol y, en particular, en las condiciones de grabación que nos importan.

Durante la inferencia, el flujo es más directo: RF-DETR actúa como puerta de entrada localizando jugadores, árbitros y balón, y las cajas de detección sirven para indicarle a SAM2 qué regiones del cuadro debe refinar. SAM2, ya ajustado, recibe el fotograma junto con esa información y devuelve máscaras más precisas para cada instancia, manteniendo además una memoria temporal que permite seguir esas máscaras a lo largo del video. En lugar de depender de interacciones manuales, el sistema se comporta como un *pipeline* integrado donde la detección y la segmentación trabajan de forma coordinada.

La calidad de este módulo se analiza revisando secuencias en las que se han anotado máscaras de referencia y comparando la estabilidad de las trayectorias, tanto del balón como de los

jugadores. El objetivo no es solo que las máscaras se vean visualmente correctas, sino que las identidades se mantengan en el tiempo y que el seguimiento sea robusto a cambios de iluminación, oclusiones parciales y variaciones en la transmisión.

5.7. Reconocimiento de dorsales y clasificación por equipos

Con jugadores y balón ya localizados y seguidos, el siguiente paso es darles identidad. Para los dorsales, la metodología prevista es bastante pragmática. A partir de las máscaras generadas por SAM2 se recortan zonas que correspondan a la espalda del jugador cuando la cámara lo permite. Sobre esos recortes se prueba primero una aproximación con SmolVLM2, pidiéndole al modelo que proponga un número probable, y luego se complementa con una ResNet entrenada o ajustada específicamente para clasificar números de camiseta. La combinación de ambas salidas, junto con la información temporal, permite estabilizar las decisiones y reducir errores puntuales.

En el caso de los equipos, el enfoque es más global. Se toman recortes donde el uniforme sea dominante, se generan *embeddings* con SigLIP2 y se agrupan mediante K-means. Como el número de equipos en un partido normal suele ser dos, el problema es manejable, pero la variabilidad de uniformes y condiciones de luz obliga a apoyarse en representaciones ricas. Cuando haya dudas, se pueden incorporar características de color en espacio HSV como apoyo, pero la intención es que la mayor parte de la discriminación provenga de las representaciones aprendidas por SigLIP2.

5.8. Evaluación e iteración del *pipeline*

La última parte de la metodología tiene que ver con cómo se mide y se ajusta todo lo anterior. No se trata solo de reportar números, sino de usar esas métricas para tomar decisiones sobre el diseño del sistema.

Para la detección se utilizan medidas estándar como **mAP**, precisión, *recall*, **F1** e IoU promedio, siempre comparando resultados entre el dominio europeo de SoccerNet y los clips de televisión colombiana y fútbol formativo. El seguimiento se revisa tanto visualmente como, cuando sea posible, con métricas de MOT sobre secuencias anotadas.

El módulo de dorsales se evalúa con *Character Accuracy Rate* y *Top-k Accuracy* sobre un conjunto de ejemplos recortados y etiquetados manualmente. El *clustering* por equipos se analiza mediante el coeficiente de silueta y comparando las etiquetas asignadas con la realidad en clips donde los equipos son fácilmente distinguibles.

A partir de estos resultados se decide si es necesario recolectar más ejemplos locales, ajustar hiperparámetros, cambiar alguna parte del *pipeline* o simplificar módulos que no aporten lo suficiente frente al costo que tienen. La intención es que la metodología no se quede en describir un diseño ideal, sino que recoja esa lógica de ir probando, midiendo y corrigiendo, siempre con la mira puesta en un sistema que pueda funcionar sobre videos reales y no solo sobre un *dataset* perfectamente curado.

Capítulo 6

RESULTADOS Y DISCUSIÓN

6.1. Modelos de Detección y Algoritmos

6.1.1. Arquitecturas YOLO Implementadas

El proyecto evalúa y compara dos versiones principales de YOLO:

YOLOv8n

- Modelo base ligero para detección en tiempo real
- Configuración estándar con 100 épocas de entrenamiento
- Tamaño de imagen: 640x640 píxeles
- Batch size: 16

YOLOv11n

- Versión mejorada con arquitectura optimizada
- Entrenamiento con hiperparámetros ajustados
- Tamaño de imagen variable: 832x832 para detección general, 1280x1280 para balón
- Optimizador AdamW con regularización mejorada

6.1.2. Configuraciones de Entrenamiento

Modelo Multi-clase (4 clases)

Listing 6.1: Configuración YOLOv11n para 4 clases

```
1 model = YOLO("yolo11n.pt")
2 model.train(
3     data=yaml_path,
4     epochs=100,
5     imgsz=832,
6     batch=16,
7     optimizer="adamw",
8     lr0=0.001,
9     lrf=0.01,
10    patience=45,
11    device=0
12 )
```

Modelo Especializado de Balón

Listing 6.2: Configuración optimizada para detección de balón

```
1 model.train(
2     data=ball_yaml,
3     epochs=80,
4     imgsz=1280,
5     batch=12,
6     optimizer="adamw",
7     lr0=0.004,
8     weight_decay=5e-4,
9     patience=30,
10    mosaic=0.2,
11    mixup=0.1,
12    iou=0.7
13 )
```

6.2. Análisis de Equipos

6.2.1. Algoritmo de Clustering

El sistema implementa un algoritmo avanzado de clustering para la identificación automática de equipos:

1. Preprocesamiento de Imagen:

- Recorte de región de torso (15 %-60 % de altura, 20 %-80 % de ancho)
- Aplicación de máscara para suprimir colores de césped
- Conversión a espacio de color HSV

2. Extracción de Características:

- Cálculo de histograma 2D en canales H y S
- Normalización de descriptores de color
- Filtrado de descriptores con información insuficiente

3. Clustering K-means:

- Agrupación en 2 clusters principales (equipos)
- Manejo de porteros como clase especial
- Asignación temporal consistente entre frames

6.2.2. Implementación del Algoritmo

El algoritmo de clustering se implementa mediante las siguientes funciones principales:

Definición 6.2.1 (Supresión de Verde). *La función `suppress_pitch_green` aplica una máscara en espacio HSV para eliminar el color del césped:*

- *Rango HSV: $H \in [35, 90]$, $S \in [40, 255]$, $V \in [40, 255]$*
- *Retorna máscara binaria invertida*

Definición 6.2.2 (Descriptor de Color). *La función `color_descriptor` genera un histograma 2D normalizado:*

- *Bins: 12x12 para canales H y S*
- *Normalización L2 del vector resultante*
- *Filtrado por mínimo de píxeles válidos (16)*

6.2.3. Persistencia de Resultados

Los resultados del clustering se almacenan en dos formatos:

- **JSON:** Asignaciones por frame con metadatos completos
- **CSV:** Mapeo `track_id` $\rightarrow$ equipo para análisis posterior

Capítulo 7

CONCLUSIONES

7.1. Contribuciones

Las principales contribuciones de este trabajo incluyen:

- Implementación exitosa de detección multi-objeto en contexto deportivo
- Algoritmo robusto de clustering por equipos basado en análisis de color
- Comparación exhaustiva entre arquitecturas YOLO modernas
- Pipeline completo desde datos brutos hasta visualización final

7.2. Conclusiones Generales

7.3. Trabajo Futuro

Bibliografía

- [1] Arthur, David y Sergei Vassilvitskii: *k-means++: The advantages of careful seeding*. En *Proceedings of the eighteenth annual ACM-SIAM symposium on Discrete algorithms*, páginas 1027–1035, 2007.
- [2] Authors, Various: *Big Data and Tactical Analysis in Elite Soccer: Future Challenges and Opportunities for Sports Science*. SpringerPlus, 5(1):1410, 2016.
- [3] Authors, Various: *Automatic Team Assignment and Jersey Number Recognition in Football Videos*. Intelligent Automation & Soft Computing, 36(3), 2023. <https://www.researchgate.net/publication/369328672>.
- [4] Authors, Various: *Automatic Team Assignment and Jersey Number Recognition in Football Videos*. Intelligent Automation & Soft Computing, 36(3), 2023. <https://www.techscience.com/iasc/v36n3/51888/html>.
- [5] Authors, Various: *Deep Learning for Action Spotting in Association Football Videos*. arXiv preprint arXiv:2410.01304, 2024. <https://arxiv.org/html/2410.01304v1>.
- [6] Authors, Various: *FootyVision: Multi-Object Tracking, Localisation, and Augmentation of Players and Ball in Football Video*. En *Proceedings of the ACM Conference*, 2024. <https://dl.acm.org/doi/fullHtml/10.1145/3665026.3665029>.
- [7] Authors, Various: *A Review of Computer Vision Technology for Football Videos*. Information, 16(5):355, 2024. <https://www.mdpi.com/2078-2489/16/5/355>.
- [8] Authors, Various: *Mapping Football Tactical Behavior and Collective Dynamics with Artificial Intelligence: A Systematic Review*. Frontiers in Sports and Active Living, 7, 2025. <https://www.frontiersin.org/journals/sports-and-active-living/articles/10.3389/fspor.2025.1569155/full>.
- [9] Bernardin, Keni y Rainer Stiefelbogen: *Evaluating multiple object tracking performance: the clear mot metrics*. En *EURASIP Journal on Image and Video Processing*, volumen 2008, páginas 1–10, 2008.
- [10] Bradski, Gary: *The opencv library*. En *Dr. Dobb's Journal: Software Tools for the Professional Programmer*, volumen 25, páginas 120–123, 2000.

- [11] Cioppa, Anthony, Adrien Deliege, Silvio Giancola, Bernard Ghanem, Marc Van Droogenbroeck y cols.: *SoccerNet 2022 challenges results*. Proceedings of the 6th International ACM Workshop on Multimedia Content Analysis in Sports, 2022.
- [12] Cioppa, Anthony, Silvio Giancola, Adrien Deliege, Le Kang, Xin Zhou, Zhiyu Cheng, Bernard Ghanem y Marc Van Droogenbroeck: *SoccerNet-Tracking: Multiple Object Tracking Dataset and Benchmark in Soccer Videos*. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, páginas 3491–3502, 2022. <https://arxiv.org/abs/2204.06918>.
- [13] Deliege, Adrien, Anthony Cioppa, Silvio Giancola, Meisam J Seikavandi, Jacob G Nasir, Bernard Ghanem y Marc Van Droogenbroeck: *SoccerNet-v2: A dataset and benchmarks for holistic understanding of broadcast soccer videos*. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, páginas 4508–4519, 2021.
- [14] Jocher, Glenn, Ayush Chaurasia, Alex Stoken, Jirka Borovec, NanoCode012, Yonghye Kwon, TaoXie y cols.: *Ultralytics YOLOv5*. GitHub repository, 2022. <https://github.com/ultralytics/yolov5>.
- [15] Lloyd, Stuart: *Least squares quantization in PCM*. IEEE transactions on information theory, 28(2):129–137, 1982.
- [16] Milan, Anton, Laura Leal-Taixé, Ian Reid, Stefan Roth y Konrad Schindler: *MOT16: A benchmark for multi-object tracking*. arXiv preprint arXiv:1603.00831, 2016.
- [17] Paszke, Adam, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan y cols.: *PyTorch: An imperative style, high-performance deep learning library*. Advances in neural information processing systems, 32, 2019.
- [18] Pedregosa, Fabian, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel y cols.: *Scikit-learn: Machine learning in Python*. Journal of machine learning research, 12:2825–2830, 2011.
- [19] Redmon, Joseph, Santosh Divvala, Ross Girshick y Ali Farhadi: *You only look once: Unified, real-time object detection*. Proceedings of the IEEE conference on computer vision and pattern recognition, páginas 779–788, 2016.
- [20] SuperAnnotate: *Computer Vision in Sports: Applications and Challenges*, 2024. <https://www.superannotate.com/blog/computer-vision-in-sports>.
- [21] Team, Google DeepMind: *TacticAI: An AI Assistant for Football Tactics*. Google DeepMind Blog, 2024. <https://deepmind.google/discover/blog/tacticai-ai-assistant-for-football-tactics/>.
- [22] Team, Ultralytics: *YOLOv11: An Overview of the Key Architectural Enhancements*. arXiv preprint arXiv:2410.17725, 2024. <https://arxiv.org/html/2410.17725v1>.

- [23] Ultralytics: *YOLO Model Comparison: YOLOv11 vs Previous Versions*. Ultralytics Blog, 2024. <https://www.ultralytics.com/blog/comparing-ultralytics-yolo11-vs-previous-yolo-models>.
- [24] Wang, Chien Yao, Alexey Bochkovskiy y Hong Yuan Mark Liao: *YOLOv8: A new state-of-the-art for object detection*. En *arXiv preprint arXiv:2305.09972*, 2023.

Apéndice A

Configuraciones y Parámetros

A.1. Parámetros de Entrenamiento

A.1.1. YOLOv8n - Configuración Base

Listing A.1: Parámetros de entrenamiento YOLOv8n

```
1 model = YOLO("yolov8n.pt")
2 model.train(
3     data=str(yaml_path),
4     epochs=100,
5     imgsz=640,
6     batch=16,
7     name="modelo_yolo_futbol",
8     project="runs/train",
9     exist_ok=True,
10    device=0
11 )
```

A.1.2. YOLOv11n - Configuración Optimizada

Listing A.2: Parámetros de entrenamiento YOLOv11n optimizados

```
1 model = YOLO("yolo11n.pt")
2 model.train(
3     data=str(yaml_path),
4     epochs=100,
5     imgsz=832,
6     batch=16,
7     optimizer="adamw",
8     lr=0.001,
9     lrf=0.01,
10    weight_decay=5e-4,
11    patience=45,
12    momentum=0.937,
```

```

13     cls=0.5,
14     box=7.5,
15     dfl=1.5,
16     warmup_epochs=3,
17     warmup_momentum=0.8,
18     warmup_bias_lr=0.1,
19     device=0,
20     amp=True,
21     cache=False,
22     workers=8
23 )

```

A.2. Configuraciones de Clustering

A.2.1. Parámetros del Algoritmo K-means

Listing A.3: Configuración del clustering por equipos

```

1 # Par metros de clustering
2 N_CLUSTERS = 2 # Dos equipos principales
3 N_INIT = 10 # N mero de inicializaciones
4 MAX_ITER = 300 # M ximo de iteraciones
5 RANDOM_STATE = 42
6
7 # Par metros de color
8 HSV_BINS = 12 # Bins para histograma HSV
9 MIN_PIXELS = 16 # M nimo de p xeles para descriptor v lido
10
11 # Rangos HSV para supresi n de verde
12 LOWER_GREEN = [35, 40, 40]
13 UPPER_GREEN = [90, 255, 255]
14
15 # Regi n de torso (porcentajes)
16 TORSO_TOP = 0.15 # 15% desde arriba
17 TORSO_BOTTOM = 0.60 # 60% desde arriba
18 TORSO_LEFT = 0.20 # 20% desde izquierda
19 TORSO_RIGHT = 0.80 # 80% desde izquierda

```

A.3. Configuraciones de Visualización

A.3.1. Parámetros del Sistema de Renderizado

Listing A.4: Configuración del sistema de visualización

```

1 # Par metros de video
2 FPS = 25

```

```

3  IMGSZ_BALL = 960      # Tamaño para detección de balón
4  IMGSZ_DET = 736      # Tamaño para detección general
5
6  # Umbrales de confianza
7  CONF_BALL = 0.25     # Confianza mínima para balón
8  IOU_BALL = 0.5       # IoU para NMS de balón
9  CONF_DET = 0.35      # Confianza mínima para detección general
10 IOU_DET = 0.7         # IoU para NMS general
11
12 # Parámetros de persistencia
13 KEEP_GAP = 5          # Frames de persistencia
14 MIN_PLAYERS_FOR_FALLBACK = 14 # Mínimo jugadores para fallback
15 FALLBACK_EVERY = 3    # Frecuencia de fallback
16
17 # Colores RGB
18 COLOR_TEAM0 = (0, 170, 255) # Azul
19 COLOR_TEAM1 = (255, 0, 170)  # Magenta
20 COLOR_GK = (0, 255, 255)     # Cian
21 COLOR_REF = (200, 200, 200)  # Gris
22 COLOR_BALL = (0, 255, 0)     # Verde

```

A.4. Estructura de Archivos de Configuración

A.4.1. Archivo data.yaml

Listing A.5: Estructura del archivo de configuración YOLO

```

1  # data.yaml para entrenamiento YOLO
2  path: /path/to/dataset
3  train: images/train
4  val: images/val
5  test: images/test
6
7  # Classes
8  nc: 4 # number of classes
9  names: ['player', 'goalkeeper', 'referee', 'ball']

```

A.4.2. Archivo ball_only.yaml

Listing A.6: Configuración específica para detección de balón

```

1  # ball_only.yaml para modelo especializado
2  path: /path/to/dataset/ball_only
3  train: images/train
4  val: images/val
5  test: images/test
6

```

```

7 # Classes
8 nc: 1 # solo bal n
9 names: ['ball']

```

A.5. Variables de Entorno

A.5.1. Configuración del Entorno de Desarrollo

Listing A.7: Variables de entorno recomendadas

```

1 # CUDA y PyTorch
2 export CUDA_VISIBLE_DEVICES=0
3 export TORCH_HOME="/path/to/torch/cache"
4
5 # Ultralytics
6 export YOLO_CONFIG_DIR="/path/to/config"
7 export YOLO_VERBOSE=True
8
9 # OpenCV
10 export OPENCV_LOG_LEVEL=ERROR
11
12 # Multiprocessing
13 export OMP_NUM_THREADS=8
14 export MKL_NUM_THREADS=8

```

A.6. Archivos de Metadatos

A.6.1. Formato gameinfo.ini

Listing A.8: Estructura del archivo gameinfo.ini

```

1 [DEFAULT]
2 trackletID_1=player team left;1;1
3 trackletID_2=player team right;2;1
4 trackletID_3=goalkeeper team left;1;2
5 trackletID_4=goalkeeper team right;2;2
6 trackletID_5=referee;0;3
7 trackletID_6=ball;0;4

```

A.6.2. Formato seqinfo.ini

Listing A.9: Estructura del archivo seqinfo.ini

```

1 [Sequence]
2 name=SNMOT-116

```

```
3 imDir=img1
4 frameRate=25
5 seqLength=3000
6 imWidth=1920
7 imHeight=1080
8 imExt=.jpg
```